

Allef Santos..... RM: 550341  
Cássio Yuji..... RM: 551491  
Débora Damaso ..... RM: 97836  
Paulo Barbosa.....RM: 550323  
Yasmin Lopes..... RM: 552314



“Desvendando o Potencial dos Dados: Explorando a AI Generativa e o Deep Analytics  
para Impulsionar o Crescimento Empresarial”

Documentação Geral

São Paulo - SP

2024

## Sumário

1 - INTRODUÇÃO .....	3
2 – DEFINIÇÃO DO PROBLEMA .....	4
3 – PROJETO E OBJETIVOS .....	4
4 – TELAS MOBILE DESENVOLVIDAS ATUALMENTE (SPRINT 3) .....	5
4-2 Funcionalidades Gerais das Telas Mobile desenvolvidas .....	6
4-3 Estrutura das telas desenvolvidas: .....	6
5 – MELHORIAS: TELAS MOBILE QUE SERÃO DESENVOLVIDAS FUTURAMENTE .....	6
6 – CONSTRUÇÃO DO MODELO E APLICAÇÃO DE MACHINE LEARNING .....	7
6-2 CONCEITO DE PROCESSAMENTO DE LINGUAGEM NATURAL (NLP) .....	7
7 – APLICAÇÃO DE PROCESSAMENTO DE LINGUAGEM NATURAL (NLP) .....	8
7-2 Análise Exploratória do Dataset: .....	8
7-3 Treinamento do Modelo de IA: .....	9
8 – BIBLIOTECAS / FRAMEWORKS .....	9
8-2 BIBLIOTECAS / FRAMEWORKS MENCIONADOS ANTERIORMENTE: .....	9
8-3 BIBLIOTECAS / FRAMEWORKS REALMENTE UTILIZADOS NA ETAPA ATUAL: .....	10
8-4 FERRAMENTAS ADICIONAIS SUGERIDAS .....	10
10 – FERRAMENTAS DOCKER .....	10
1-2 RECURSOS DA AZURE .....	11
11 – DIAGRAMA DA ARQUITETURA (ARCHIMATE) .....	12
12 – CONCLUSÃO E PLANOS DE MELHORIA .....	13
13 – LINKS ÚTEIS (VIDEO PITCH E REPOSITÓRIO).....	13

## 1 - INTRODUÇÃO

Nos últimos anos, a explosão de dados tem sido uma realidade inegável para as empresas em todos os setores. No entanto, o verdadeiro desafio não reside apenas na coleta massiva desses dados, mas sim em extrair insights valiosos que possam impulsionar o crescimento empresarial. É aqui que entram em cena duas tecnologias revolucionárias: Inteligência Artificial (IA) Generativa e Deep Analytics.

A IA Generativa, um ramo da inteligência artificial que se concentra na criação de novos dados, imagens, textos e até mesmo música, oferece um novo paradigma para a inovação. Por meio de algoritmos avançados, como redes neurais generativas adversariais (GANs), as empresas podem não apenas analisar dados existentes, mas também gerar novos dados sintéticos que podem ser utilizados para melhorar produtos, personalizar experiências do cliente e até mesmo prever tendências de mercado.

Por outro lado, o Deep Analytics vai além da análise superficial de dados e mergulha nas camadas mais profundas para desvendar insights significativos. Utilizando técnicas de machine learning avançadas, como redes neurais profundas e algoritmos de aprendizado não supervisionado, o Deep Analytics é capaz de identificar padrões complexos, correlações sutis e anomalias ocultas nos dados empresariais. Isso permite que as organizações tomem decisões mais informadas, otimizem processos internos e identifiquem novas oportunidades de negócios.

Ao combinar IA Generativa e Deep Analytics, as empresas podem criar um ciclo virtuoso de inovação e crescimento. Por exemplo, uma empresa de varejo pode usar IA Generativa para criar simulações de comportamento de compra de clientes e, em seguida, aplicar Deep Analytics para identificar os drivers subjacentes desse comportamento. Com esses insights, a empresa pode desenvolver estratégias de marketing mais eficazes, melhorar a segmentação de clientes e otimizar o mix de produtos, tudo levando a um aumento tangível nas receitas e lucros.

No entanto, é importante notar que, embora o potencial dessas tecnologias seja imenso, elas também trazem consigo desafios únicos, como questões éticas relacionadas à privacidade dos dados e viés algorítmico. Portanto, as empresas devem adotar uma abordagem responsável ao implementar IA Generativa e Deep Analytics, garantindo que os benefícios sejam maximizados enquanto os riscos são mitigados.

Em suma, o futuro do crescimento empresarial está intrinsecamente ligado à capacidade das organizações de desvendar o potencial dos dados por meio da IA Generativa e do Deep Analytics. Ao abraçar essas tecnologias de maneira estratégica e ética, as empresas podem posicionar-se na vanguarda da inovação e prosperar em um mundo cada vez mais orientado por dados.

### 1-2 Justificativa

Nosso objetivo é dar uma solução de alcance maximizado, ou seja, que possa ser utilizada por todos os tipos de clientes que a Plusoft presta serviços e não somente em um nicho específico.

Com isso, há diversos benefícios e não somente a Plusoft, mas também com os clientes e seus consumidores, já que as empresas terão um mapeamento sentimental dos compradores aos adquirirem um produto ou serviço.

## 2 – DEFINIÇÃO DO PROBLEMA

A coleta e análise de feedback são cruciais para o sucesso de qualquer empresa. No entanto, diversos desafios podem dificultar esse processo, impedindo a organização de alcançar todo o potencial do feedback do cliente:

- **Feedbacks Ausentes:** Uma grande quantidade de produtos com feedbacks ausentes indica baixo engajamento do consumidor. Isso torna difícil identificar problemas e oportunidades de melhoria, além de limitar a capacidade da empresa de capitalizar os aspectos positivos dos produtos.
- **Análise Complexa:** A vasta quantidade de dados coletados, tanto estruturados quanto não estruturados, torna desafiador extrair insights relevantes e acionáveis. A falta de expertise em análise de dados dificulta a identificação dos motivos e tópicos subjacentes aos feedbacks positivos e negativos.
- **Demanda por agilidade:** A demanda por soluções rápidas exige a capacidade de identificar feedbacks recentes, sinais de alerta e oportunidades em tempo real. A dificuldade nesse aspecto pode levar à perda de chances de fidelizar clientes e aprimorar a experiência do usuário.

Esses desafios podem ter consequências negativas para a empresa, como dificuldade na identificação e resolução de problemas, perda de oportunidades de melhoria, insatisfação do cliente, dificuldade na fidelização de clientes, desvantagens competitivas.

## 3 – PROJETO E OBJETIVOS

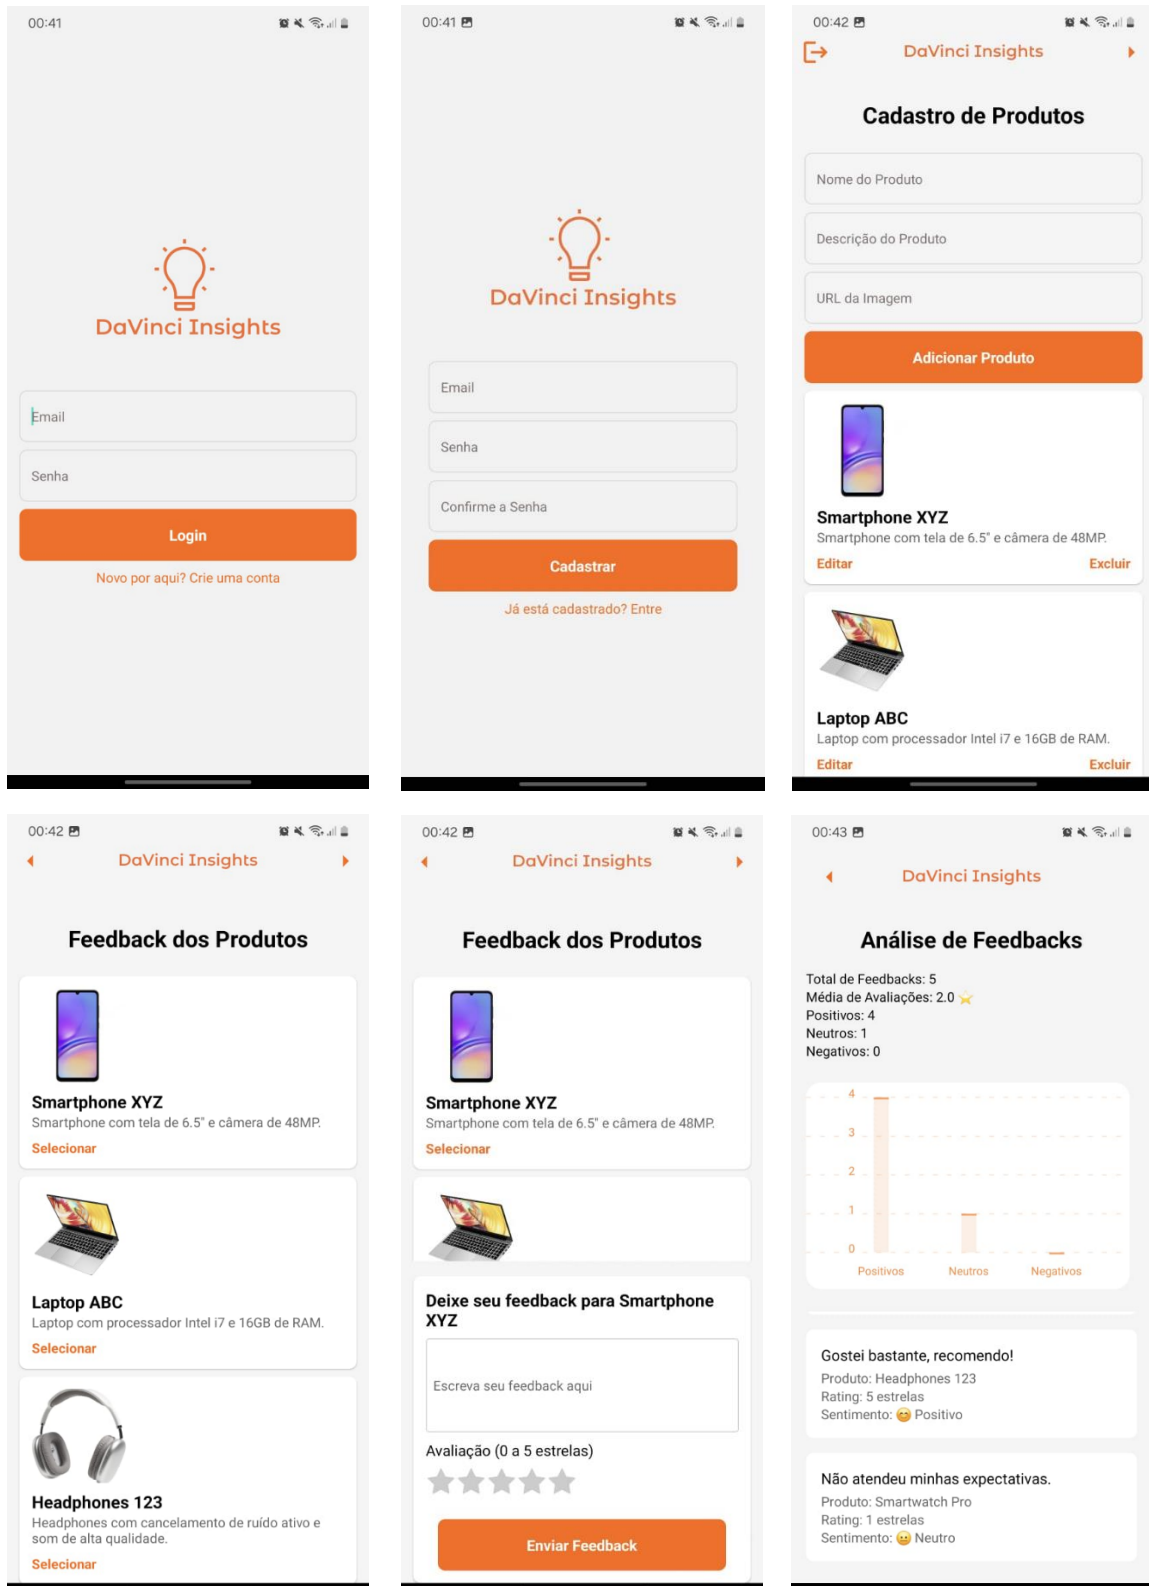
O projeto visa implementar um sistema avançado de processamento de dados para análise sentimental dos feedbacks dos clientes. O foco é duplo: avaliar tópicos relevantes nas opiniões dos usuários que já forneceram seu parecer sobre produtos ou serviços e também engajar aqueles que ainda não o fizeram. O objetivo é extrair insights valiosos que permitam às empresas compreender as razões por trás das avaliações — sejam elas positivas, negativas, neutras ou ausentes.

Será desenvolvido um mecanismo de incentivos (cashbacks, descontos) para encorajar os consumidores a adotarem o hábito de avaliar suas experiências de compra, reduzir o número de avaliações ausentes e incentivar novas compras. Isso se baseia na premissa de que as avaliações de consumidores anteriores são um elemento chave na decisão de novos clientes de adquirir um produto.

Nossa solução irá iniciar com a entrada do DataSet da empresa em nossa aplicação e posteriormente, passar pelo processo de Data Analytics com todas as etapas que desenvolvemos e por fim, um gráfico para melhorar a visualização dos resultados em relação aos feedbacks e quais foram as palavras mais utilizadas em cada polo de avaliação (positivo e negativo). Com essas informações centralizadas, a empresa poderá investigar por exemplo (fictício), porque um certo produto possui uma melhor avaliação sendo vendido no estado de São Paulo do que no estado de Pernambuco (mesmo o produto sendo exatamente o mesmo), neste caso, podem apresentar problemas com a experiência de entrega, seja ela o preço elevado, devido a dificuldade de acessar o local, como não ter entregas para esses endereços.

#### 4 – TELAS MOBILE DESENVOLVIDAS ATUALMENTE (SPRINT 3)

Dentre as telas mobile apresentadas na documentação da sprint 2 (em protótipo do figma), algumas telas foram desenvolvidas nesta etapa (agora na sprint 3) utilizando react. Vale ressaltar que mais telas serão desenvolvidas na Sprint 4 para suprir outras partes de nossa proposta. Aqui estão prints das principais telas desenvolvidas atualmente e suas descrições abaixo:



## 4-2 Funcionalidades Gerais das Telas Mobile desenvolvidas

- **Autenticação:**  
O aplicativo permite que os usuários façam login ou se cadastrem usando o Firebase Authentication.
- **Cadastro de Produtos:**  
Os usuários podem registrar os produtos.
- **Feedback dos Clientes:**  
Após o registro do produto, os usuários podem deixar feedbacks.
- **Análise de Sentimentos:**  
Utilizando a API de análise de sentimentos, o aplicativo processa o feedback dos clientes, identificando se as opiniões são positivas, negativas ou neutras.
- **Visualização dos Insights:**  
Os usuários podem ver uma análise detalhada dos feedbacks, ajudando as empresas a entender o que está funcionando e o que precisa ser melhorado.

## 4-3 Estrutura das telas desenvolvidas:

- **Login:**  
Permite que os usuários façam login no aplicativo usando Firebase Authentication. Campos de entrada para email e senha. Botão para redirecionar para a tela de cadastro (SignUp) se o usuário ainda não tiver uma conta.
- **SignUp:**  
Tela para registrar novos usuários, também utilizando Firebase Authentication. Campos para inserir email, senha e confirmação de senha. Botão para criar uma nova conta e redirecionar para a tela de cadastro (Login) se o usuário já tiver uma conta.
- **RegisterProduct:**  
Tela onde os usuários podem registrar os produtos. Formulário com campos como nome do produto, descrição e link da imagem do produto. Botão para salvar o produto e prosseguir para o feedback.
- **CustomerFeedback:**  
Tela onde os usuários podem deixar feedback sobre os produtos registrados. Campo de texto para inserir a avaliação e número de estrelas(0-5). Botão para enviar o feedback, que será processado pela API de análise de sentimentos.
- **AnalysisFeedback:**  
Tela para exibir a análise do feedback do cliente. Mostra uma visualização dos sentimentos identificados (positivos, negativos ou neutros) através da integração com a API de análise de sentimentos. Exibe um gráfico resumindo os feedbacks para que as empresas possam obter insights acionáveis.

## 5 – MELHORIAS: TELAS MOBILE QUE SERÃO DESENVOLVIDAS FUTURAMENTE

Para contemplar o escopo de nossa proposta, será desenvolvido um mecanismo para incentivar consumidores que não realizaram feedbacks (feedbacks ausentes) à avaliarem os produtos, no qual contemplará sugestões como envio de cashback, cupons de desconto ou moedas como incentivos para o aumento do número de feedbacks.

## 6 – CONSTRUÇÃO DO MODELO E APLICAÇÃO DE MACHINE LEARNING

### 6-2 CONCEITO DE PROCESSAMENTO DE LINGUAGEM NATURAL (NLP)

O processamento de linguagem natural (PLN), ou em inglês Natural Language Processing (NLP), combina linguística computacional, modelagem baseada em regras da linguagem humana e modelos estatísticos, de machine learning e de deep learning, para permitir que os computadores processem a linguagem humana na forma de dados de texto ou voz e “entendam” seu significado integral, pode ser usado para identificar a **intenção e o sentimento** do locutor ou escritor.



O PLN envolve várias tarefas, que incluem tradução automática (traduzir texto de um idioma para outro), reconhecimento de fala (converter fala falada em texto escrito), geração de linguagem natural (converter informações de bancos de dados em linguagem compreensível), e muitos outros.

Dentre os desafios da PLN, é necessário observar que a linguagem humana é repleta de ambiguidades, como homônimos, homófonos, sarcasmo, expressões idiomáticas e metáforas, diante disso, programadores devem estar atentos à ensinar aplicativos orientados por linguagem natural a reconhecer e entender essas nuances.

Existem vários processamentos de linguagem natural (PLN) que podem ser aplicados a um texto para extrair informações, entender o significado e realizar tarefas específicas. Aqui estão alguns dos principais exemplos:

1. Tokenização: Divide o texto em unidades menores, como palavras ou frases.
2. Análise Morfológica: Identifica as partes constituintes das palavras, como raízes e sufixos.
3. Análise Sintática: Analisa a estrutura gramatical das sentenças, identificando a relação entre as palavras.
4. Análise Semântica: Compreende o significado das palavras e frases em um contexto específico.
5. Desambiguação Semântica: Resolve ambiguidades de significado em palavras ou frases.

6. Reconhecimento de Entidades Nomeadas (NER): Identifica e classifica entidades, como nomes de pessoas, locais e organizações.
7. Extração de Relacionamentos: Descobre relações semânticas entre entidades no texto.
8. Classificação de Texto: Atribui categorias ou rótulos a textos com base no conteúdo.
9. Agrupamento de Texto: Agrupa documentos ou sentenças semelhantes.
10. Sumarização de Texto: Cria resumos concisos do conteúdo de um texto.
11. Tradução Automática: Converte texto de uma língua para outra.

## 7 – APLICAÇÃO DE PROCESSAMENTO DE LINGUAGEM NATURAL (NLP)

No contexto do nosso projeto, o Processamento de Linguagem Natural foi utilizado para identificar sentimentos (negativos, positivos) dos clientes em relação ao produto.

O nosso modelo em python foi criado com base em alguns passos:

### 7-2 Análise Exploratória do Dataset:

Nesta análise (exposta no arquivo ***AnaliseDataset.ipynb***), exploramos o dataset de vendas da Olist. Este dataset contém diversos dados sobre clientes, geolocalização, pedidos, pagamentos, avaliações, produtos e vendedores divididos em vários arquivos do tipo .csv. O arquivo base de nosso estudo foi o *olist\_order\_reviews\_dataset.csv*.

Em relação à **distribuição das avaliações** foi verificado, entre os achados da análise, que há uma predominância de feedbacks favoráveis (entre 4 e 5), que representam mais de 75% das avaliações. As avaliações notas 3, que poderiam ser mais “neutras” representam uma porção muito pequena no conjunto (apenas 8%), o que fez com que eu separasse o modelo posteriormente entre negativos e positivos, optando posteriormente em criar um modelo de classificação binária.

Ao analisar os comentários, foi verificado que os comentários positivos frequentemente mencionam satisfação com o produto (ex.: "Meu marido adorou a carteira", "ótimo produto e entrega rápida") e os negativos são bem diretos sobre os problemas, como "não está funcionando o produto" ou "produto de má qualidade". Comentários neutros são mistos, como "apesar do atraso, recomendo" ou "a foto de ilustração não condiz". Alguns exemplos sugerem que a qualidade do produto e a pontualidade na entrega são tópicos centrais, e problemas com funcionamento ou qualidade têm mais destaque nas críticas.

Ao verificar a média de avaliações por produto, foi visto que cada produto recebeu em média 1 avaliação, e o produto com mais avaliações tem apenas 3 avaliações. Isso mostra uma dispersão de avaliações, com poucos produtos acumulando feedback mais significativo. Este problema observado indica que há uma quantidade grande de **feedbacks ausentes**.

Uma solução viável para estimular os clientes à avaliarem suas compras, seria utilizar nosso sistema de recompensas à avaliações, com a possibilidade de contactar o cliente e oferecer benefícios (como moedas, cashback ou cupons) caso avaliar o produto comprado.



### 7-3 Treinamento do Modelo de IA:

O modelo foi treinado no arquivo **TreinamentoModelo.ipynb** e exportado como **modelo\_analise\_sentimento.pkl** com acurácia de 92,7% utilizando o Logistic Regression.

Também foi treinado o Random Forest, porém com a acurácia de 91,9%. Nosso modelo, neste momento, é de classificação binária que identifica sentimentos positivos e negativos. Mais detalhes sobre outras métricas de avaliação como *acurácia*, *precisão*, *recall* e *F1-score* podem ser vistos na discussão do arquivo ipynb mencionado acima.

Em relação às dificuldades encontradas, vale ressaltar que um outro modelo foi testado, treinado e descartado posteriormente. O modelo continha Positivos, Neutros e Negativos, com 84% de acurácia. Porém, o modelo descartado obteve resultados ruins na avaliação de feedbacks neutros e por este motivo foi ignorado nesta entrega. Dado ao fato de que feedbacks neutros são uma porção minoritária do dataset (8%), foram utilizadas técnicas como aumentar os dados e otimizar hiper parâmetros, mas sem alterações visíveis no resultado final. Futuramente, será criado um modelo aprimorado para suprir esta necessidade de incluir feedbacks neutros com melhores resultados utilizando outro conjunto de dados.

Foram realizadas limpeza e normalização dos dados, como por exemplo, drop de colunas desnecessárias para a análise e técnicas de processamento de texto utilizando alguns recursos de NLP como: Remoção de pontuações, Tokenização, remoção de stopwords, normalização de maiúsculas e minúsculas, stemming.

O processo de vetorização foi realizado com o **TF-IDF** do Scikit-learn, que transforma texto em vetores numéricos baseados na importância de palavras nos comentários, sendo uma das partes fundamentais para o funcionamento do modelo de análise de sentimentos.

Em relação ao deploy do modelo, ele será disponibilizado para ser utilizado em uma API, e re-treinado posteriormente com melhorias futuras.

## 8 – BIBLIOTECAS / FRAMEWORKS

Dentre as bibliotecas e frameworks que foram sugeridos na fase da sprint 2, houve algumas alterações na escolha destes, devido à alguns problemas de incompatibilidade de versões entre eles, dentre outros. Então, para auxiliar com este problema, a análise do dataset e o desenvolvimento do modelo foi realizado no google colab e com algumas mudanças de bibliotecas nesta entrega da sprint 3.

### 8-2 BIBLIOTECAS / FRAMEWORKS MENCIONADOS ANTERIORMENTE:

- **Scikit-learn:** Mencionado como ferramenta principal para Machine Learning, usado para categorizar e analisar o feedback dos clientes.
- **TensorFlow e Keras:** Indicados para deep learning e construção de modelos personalizados.
- **Pandas e NumPy:** Sugeridos para manipulação e análise de dados.
- **Matplotlib ou Seaborn:** Para visualização de gráficos e insights.
- **Plotly:** Apresentado para gráficos interativos.
- **NLTK:** Proposto para processamento de linguagem natural em Python.
- **TextBlob:** Mencionado como uma ferramenta simples para análise de sentimentos.
- **spaCy:** Indicada para tokenização, parsing e vetorização de palavras.
- **Hugging Face Transformers:** Sugestão para uso de modelos de linguagem pré-treinados.

### 8-3 BIBLIOTECAS / FRAMEWORKS REALMENTE UTILIZADOS NA ETAPA ATUAL:

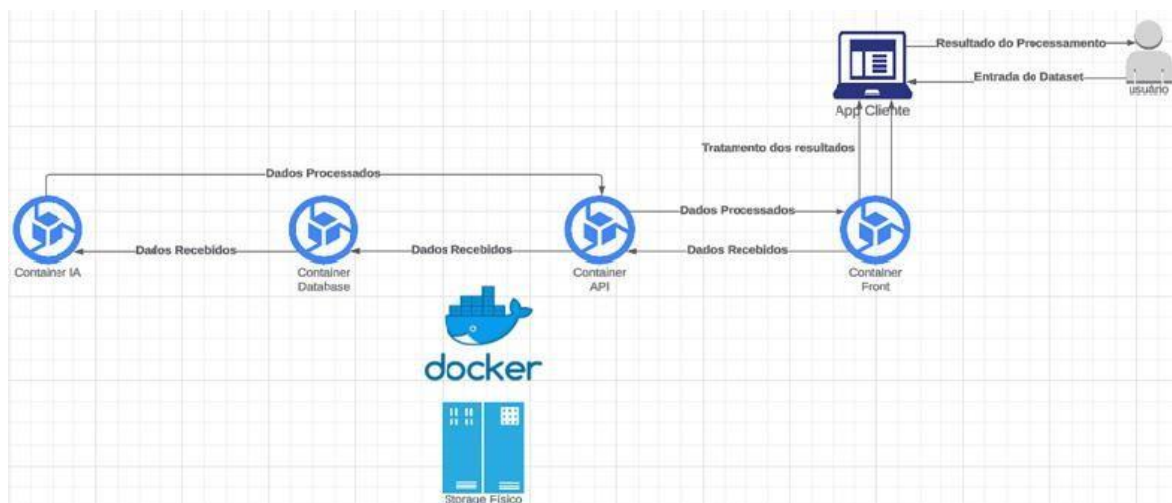
- **Scikit-learn:** Usado como previsto, sendo a principal biblioteca para a construção do modelo de Machine Learning. Usado com diversas funcionalidades: Para separar os dados em conjuntos de treino e teste (`train_test_split`), para transformar o texto em vetores numéricos (`TfidfVectorizer`), para treinar um modelo de classificação (`LogisticRegression`) e para avaliar o desempenho do modelo (`classification_report` e `accuracy_score`).
- **Pandas e NumPy:** Usados como previsto para manipulação de dados, carregar datasets e verificação de valores nulos, além de suporte em várias operações numéricas.
- **Matplotlib e Seaborn:** Usado como previsto para a visualização de dados. Criamos gráficos para a distribuição das avaliações e análise de sentimentos.
- **NLTK:** Usado conforme planejado para o pré-processamento de texto. Aplicamos a tokenização, remoção de stopwords e limpeza de texto para preparar os dados para o modelo.
- **Re (expressões regulares):** Não mencionado na versão anterior, mas utilizado na nossa implementação atual para a limpeza de caracteres especiais e pontuações nos textos das avaliações.
- **Joblib:** Não foi mencionada anteriormente, mas foi usado nesta etapa atual para salvar e carregar modelos treinados.

### 8-4 FERRAMENTAS ADICIONAIS SUGERIDAS

- **Power BI:** Ferramentas de visualização de dados que podem ser usadas para criar dashboards e gráficos interativos a partir dos insights extraídos estão entre as sugestões possíveis de entrega da próxima fase (Sprint 4). O foco na sprint 3 (etapa atual) foi suprir a etapa da proposta que sugere um modelo de IA de análise de sentimentos nos feedbacks. A etapa futura terá um desenvolvimento mais complexo, que visa permitir a entrada de um dataset e manipular o mesmo para obter insights de forma descomplicada, o que abre a possibilidade de uso desta ferramenta caso necessário.

## 10 – FERRAMENTAS DOCKER

Como o projeto analisa o grande fluxo de dados de feedbacks e comentários, faz-se necessário a implementação de uma infraestrutura para a virtualização em contêineres e micro serviços. Os contêineres Docker proporcionam isolamento entre os diferentes componentes da aplicação, aumentando a segurança e a estabilidade do sistema. Este sistema consiste em um frontend desenvolvido em uma aplicação web moderna e uma API em Java no backend, que atua como uma camada intermediária entre o frontend e a IA.



## Descrição da infraestrutura docker:

### Entrada:

- Storage Físico: máquina com os hardwares necessários para a virtualização, como o processador, memória RAM, disco e placa de rede.
- Docker: Ferramenta que utilizaremos para o uso e gerenciamento dos containers de modo mais eficiente e intuitivo.
- App Cliente: aplicativo final e interface que o usuário irá interagir.
- Container Front: container responsável por ter todas as dependências e entrada do front, e envia esses dados para a API.
- Container API: container responsável pelo funcionamento da API, que irá intermediar a comunicação do front, Database e IA.
- Container Database: container que irá receber os dados trazidos pela API e depois enviar esses dados para a IA.
- Container IA: container que irá receber todos os dados e é responsável por todo o processamento deles.

### Saída:

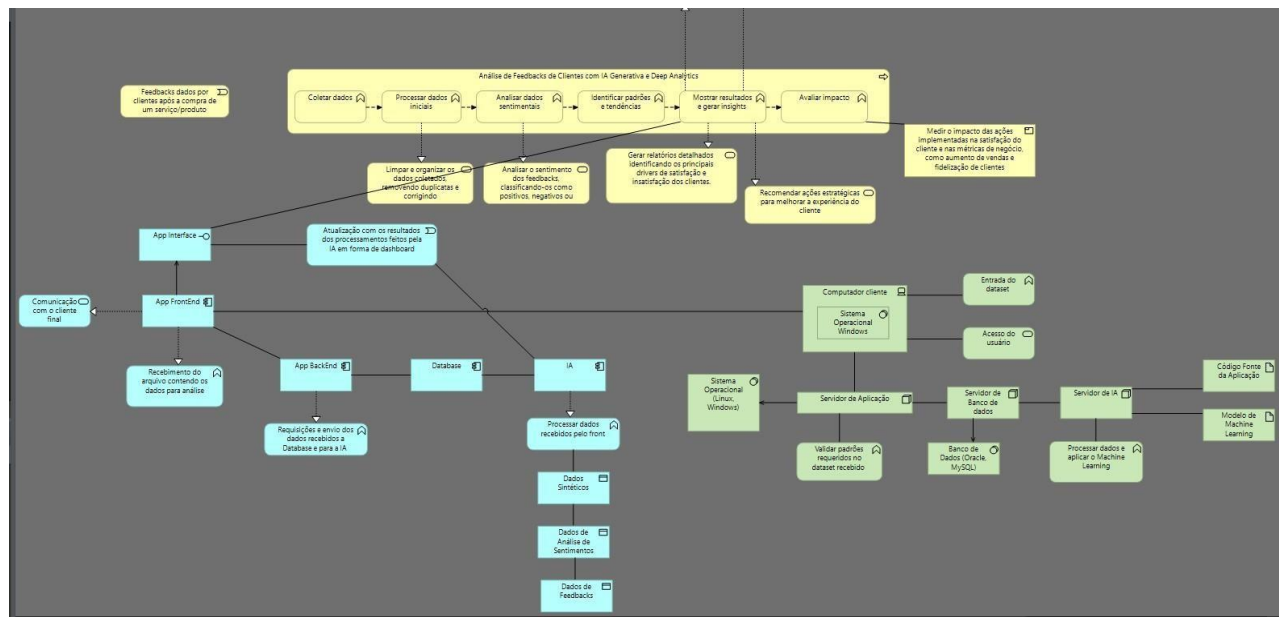
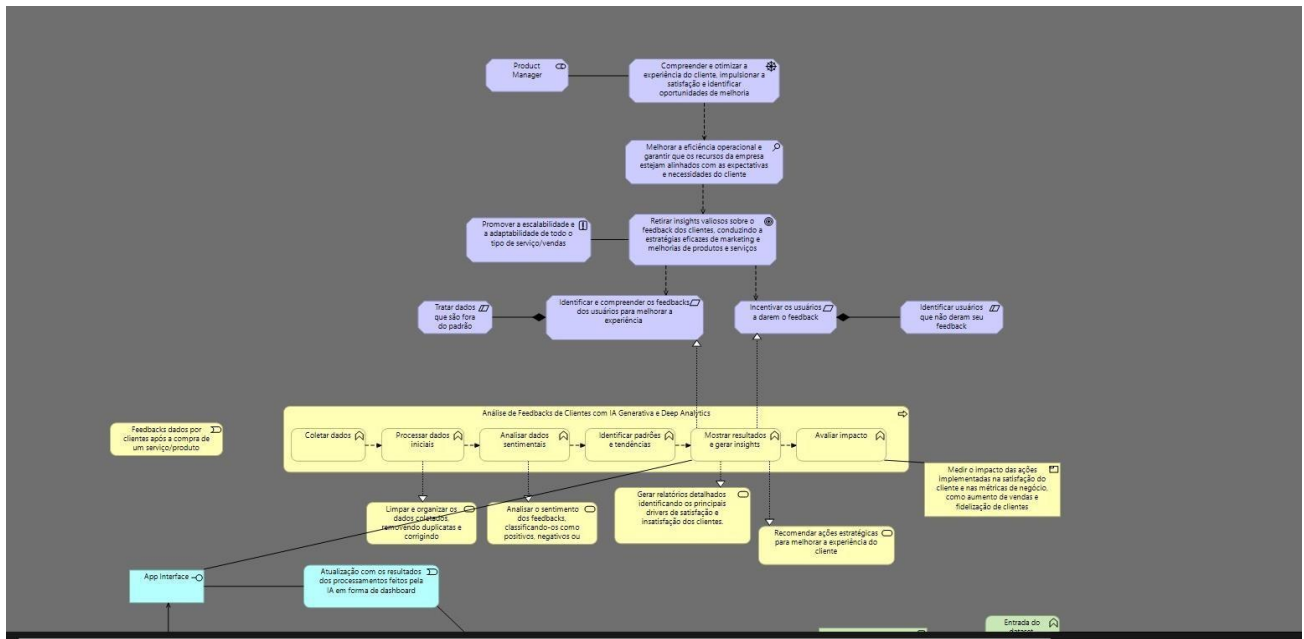
- Com o resultado do processamento, eles serão levados pela API até o front, onde passará por um tratamento para que os insights sejam mais visuais e de fácil entendimento do usuário, como gráficos e pequenas descrições dos resultados com alguns indicativos de melhora.

## 1-2 RECURSOS DA AZURE

- Virtual Machine (IaaS)  
As Máquinas Virtuais são um exemplo clássico de IaaS. Elas nos permitirão que possamos configurar e gerenciar nossos servidores virtuais, proporcionando flexibilidade e escalabilidade. Com as VMs, temos controle sobre o sistema operacional, armazenamento, e a configuração da rede, permitindo ajustar os recursos de computação (como CPU, memória e disco) de acordo com as necessidades específicas. Isto elimina a necessidade de adquirir e manter hardware físico, oferecendo uma infraestrutura sob demanda.
- Load Balancer (IaaS)  
Garante a disponibilidade e distribuição eficiente de tráfego entre as máquinas virtuais, iremos utilizar o Load Balancer, ou seja, um balanceador. Este serviço é responsável por distribuir automaticamente as solicitações entre as VMs (Front e Back), de forma que nenhuma máquina seja sobrecarregada e que nossa solução permaneça responsiva mesmo durante picos de demanda.
- VNet (IaaS)  
É responsável por garantir um isolamento e proteger a infraestrutura da aplicação, permite a comunicação entre as VM's, balanceador de carga e outros recursos de rede, assim como facilitar a implementação de políticas de segurança como firewalls e grupos de segurança de rede.
- Storage Account (PaaS)  
Será utilizado para armazenar datasets, resultados de análises, logs e backups. Além de oferecer alta disponibilidade, redundância geográfica, acesso seguro e a possibilidade de compartilhamento de grandes massas de dados.

## 11- DIAGRAMA DA ARQUITETURA (ARCHIMATE)

Para garantir uma visualização mais ampliada deste diagrama, as imagens e archimate do mesmo será também disponibilizada dentro da pasta da entrega, de modo separado deste documento.



## 12 – CONCLUSÃO E PLANOS DE MELHORIA

Este projeto destaca a importância do processamento de dados para compreender e agir sobre os feedbacks dos usuários. Ao analisar esses feedbacks, as empresas podem identificar as razões por trás das avaliações, desenvolver estratégias para melhorar a satisfação do cliente e, conseqüentemente, atrair novos compradores. Ao reconhecer que as avaliações dos clientes desempenham um papel crucial na decisão de compra, é necessário também estimular os clientes à adotarem o hábito de avaliar as suas compras, como também é fundamental investir em análise de feedbacks para o sucesso e a competitividade das empresas no mercado.

Em suma, dentre as melhorias que serão realizadas futuramente, estão o desenvolvimento de notas telas da aplicação mobile além das que já foram desenvolvidas agora na sprint 3 em react, com o objetivo de contemplar mais requisitos da proposta que foram mencionados anteriormente, como por exemplo, as telas de nosso sistema de recompensa e estímulos aos feedbacks. Vale ressaltar que o modelo atual de IA também será aprimorado para que possa responder com maior precisão especificamente em relação aos feedbacks do tipo neutro. Além de que outras ferramentas sugeridas nesta documentação podem ser utilizadas para analisar datasets de forma mais profunda e dinâmica, para que nossa proposta seja entregue da maneira mais ampla possível na última fase.

## 13 – LINKS ÚTEIS

- Link do vídeo Pitch:

<https://youtube.com/playlist?list=PL1zapSlcAQTDyAUScqkEolyq5jqjomnd&si=4Yg6hqlYDXdXGVG3>

- Link da pasta completa no google drive:

[https://drive.google.com/drive/folders/1w7pozCVdJworLfclOYjfBSolqhi4SL99?usp=drive\\_link](https://drive.google.com/drive/folders/1w7pozCVdJworLfclOYjfBSolqhi4SL99?usp=drive_link)

- Link do github:

<https://github.com/debsdamaso/DaVinciIOT>